Centro Universitario de Guadalajara

Fundamentos de Ingeniería de Datos

ENTREGABLE 1

Mapa del Flujo de Datos +
Miniespecificación de Requerimientos e Ingesta de Datos

Nombre: Bethzy Sarahi Salcido Toro
Código: 220443324

Nombre: Guillermo Fernando Ornelas Jimenez
Código: 225361237

Fecha de entrega: 5 de octubre de 2026

Docente: Gustavo Candelario Guzmán

1. Mapa del Flujo de Datos (E1.1)

El siguiente diagrama representa el flujo completo de datos construido durante la práctica con los tres datasets seleccionados de Kaggle: origen (API externa), proceso de ingesta, transformación inicial, destino en SQLite (capa raw) y los SLO de datos sugeridos.

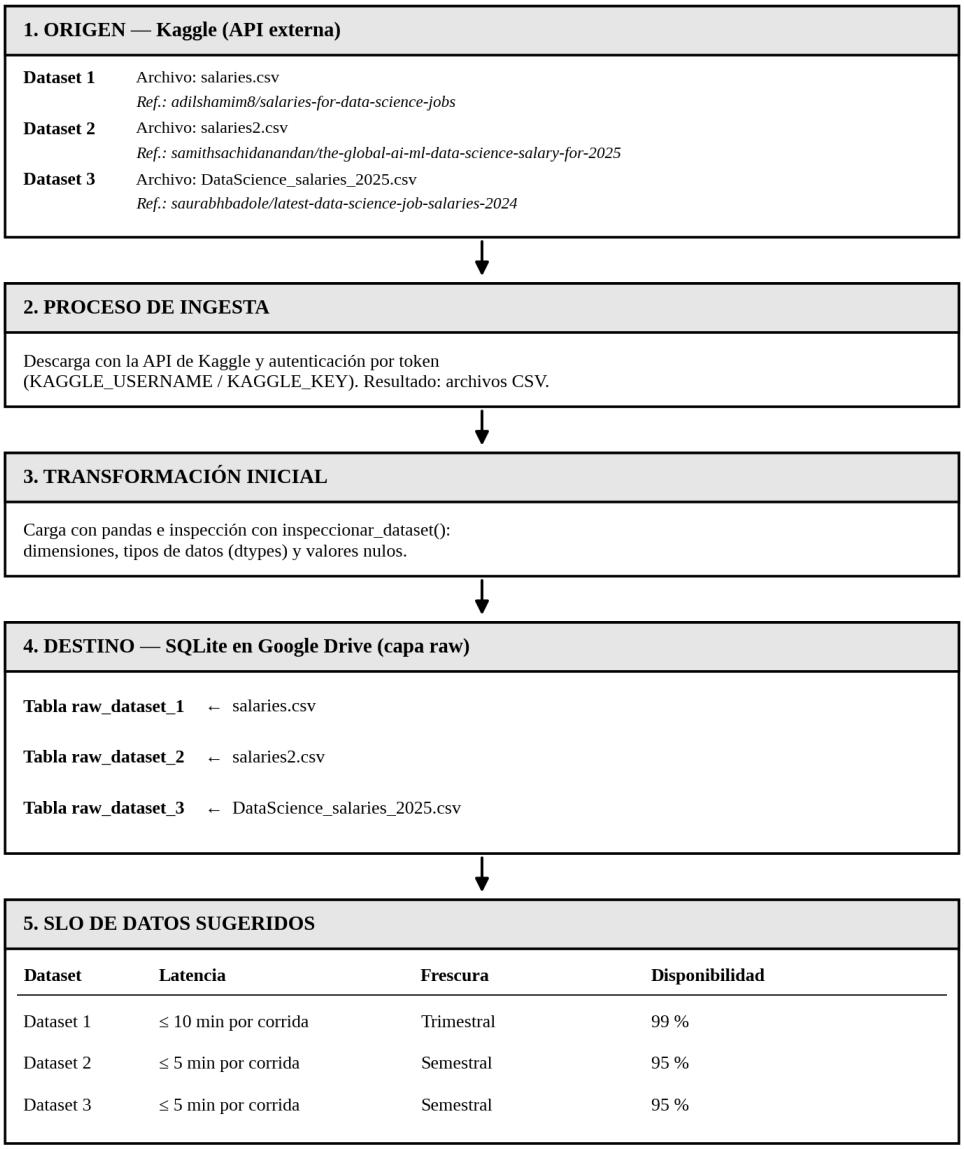


Figura 1. Mapa del flujo de datos.

2. Práctica de Ingesta de Datos (E1.2)

2.1 Datasets seleccionados

Los tres datasets pertenecen al sector tecnológico y comparten el mismo esquema de 11 columnas (work_year, experience_level, employment_type, job_title, salary, salary_currency, salary_in_usd, employee_residence, remote_ratio, company_location, company_size).

Tabla 1. Datasets seleccionados.

#	Referencia en Kaggle	Descripción
1	Archivo: salaries.csv Ref.: adilshamim8/salaries-for-data-science-jobs	Salarios globales de roles de datos, IA y tecnología (2020–2025): 151,445 registros × 11 columnas. Es el dataset con mayor volumen y cobertura (78,726 registros de 2025).
2	Archivo: salaries2.csv Ref.: samithsachidanandan/the-global-ai-ml-data-science-salary-for-2025	Salarios de roles tecnológicos (2020–2025): 88,584 registros × 11 columnas, 312 puestos distintos y 90 países de ubicación de la empresa.
3	Archivo: DataScience_salaries_2025.csv Ref.: saurabhbadole/latest-data-science-job-salaries-2024	Salarios de ciencia de datos y roles afines (2020–2025): 93,597 registros × 11 columnas, 317 puestos distintos y 90 países de ubicación de la empresa.

2.2 Esquema de la ruta de almacenamiento en Google Drive

Los archivos se organizan en una carpeta maestra de Google Drive con dos subcarpetas: una para los CSV descargados de Kaggle y otra para la base de datos SQLite (capa raw).

```
Google Drive/
└── MASTER_DRIVE_FOLDER
    ├── KAGGLE_DRIVE_FOLDER/        (CSV originales descargados)
    │   ├── salaries.csv
    │   ├── salaries2.csv
    │   └── DataScience_salaries_2025.csv
    └── DB_DRIVE_FOLDER/            (capa raw)
        └── base SQLite (.db)
            ├── raw_dataset_1   ← salaries.csv
            ├── raw_dataset_2   ← salaries2.csv
            └── raw_dataset_3   ← DataScience_salaries_2025.csv
```

3. Miniespecificación de Requerimientos (E1.2)

La siguiente tabla se elaboró con base en la inspección con pandas de los tres datasets descargados.

Tabla 2. Miniespecificación técnica.

Dataset	Frescura requerida	Calidad mínima aceptable	Retención sugerida
Dataset 1 (salaries.csv)	Trimestral. Los salarios cambian lentamente, pero el dataset llega hasta 2025 y debe renovarse cuando se publique una nueva versión.	0 % de nulos en las 11 columnas (resultado observado: 0 nulos). Sin nulos en columnas críticas: work_year, job_title, experience_level y salary_in_usd; salary_in_usd > 0 (mínimo observado: 15,000). Tipos correctos (int64 y texto) y remote_ratio solo con 0, 50 o 100. Duplicados exactos observados: 79,532 (52.5 %); deben identificarse y tratarse en la siguiente capa.	5 años, para análisis de tendencias salariales; después se archiva.
Dataset 2 (salaries2.csv)	Semestral. Tiene menos registros de 2025 (15,875) y se solapa con los otros datasets.	0 % de nulos en las 11 columnas (resultado observado: 0 nulos). Columnas críticas sin nulos; salary_in_usd > 0 (mínimo observado: 15,000). Duplicados exactos observados: 44,340 (50.1 %). Tipos correctos y valores de categorías dentro de los catálogos esperados.	2 años, ya que su contenido es en gran parte redundante con el dataset 1; después se archiva.
Dataset 3 (DataScience_salaries_2025.csv)	Semestral. Cobertura 2020–2025 con 20,886 registros de 2025.	0 % de nulos en las 11 columnas (resultado observado: 0 nulos). Columnas críticas sin nulos; salary_in_usd > 0 (mínimo observado: 15,000). Duplicados exactos observados: 46,960 (50.2 %). Tipos correctos y valores de categorías dentro de los catálogos esperados.	2 años, por su redundancia con el dataset 1; después se archiva.

Supuestos

- **¿Con qué frecuencia deberían actualizarse estos datos en un sistema en producción?** Los datos son de salarios anuales, por lo que no requieren actualización en tiempo real. En producción se sugiere una actualización trimestral del dataset 1 (fuente principal) y semestral de los datasets 2 y 3, además de una revisión mensual de si Kaggle publicó una versión nueva.
- **¿Qué columnas con valores nulos representan un riesgo para el análisis? ¿Por qué?** En la inspección ninguna columna de los tres datasets presentó valores nulos, por lo que actualmente no hay columnas en riesgo por este motivo. Si aparecieran nulos en futuras cargas, las más críticas serían salary_in_usd (variable objetivo y base de comparación entre monedas), work_year (permite el análisis temporal), job_title y experience_level (segmentan los salarios) y salary_currency (necesaria para validar la conversión a USD).
- **¿Cuánto tiempo tendría sentido conservar estos datos antes de archivarlos o eliminarlos?** El dataset 1 se conservaría 5 años para analizar tendencias salariales; los datasets 2 y 3, 2 años, porque son en gran parte redundantes con el primero. Pasado ese tiempo se archivan o se eliminan para reducir costos de almacenamiento y mantenimiento.

4. Preguntas de Reflexión

1. ¿Qué ventajas tiene usar una API para la ingesta de datos en comparación con descargar archivos manualmente?

La API permite automatizar la descarga y repetirla siempre de la misma forma, lo que hace el proceso reproducible y reduce los errores humanos. La autenticación por token controla el acceso, y se puede elegir exactamente el dataset y la versión que se descarga. Además, la ingesta se puede programar e integrar en un pipeline, de modo que actualizar los datos solo requiere volver a ejecutar el código y no repetir pasos manuales.

2. ¿Por qué es importante guardar los datos en una capa raw sin modificaciones antes de transformarlos?

La capa raw conserva una copia fiel de la fuente original, que funciona como punto de referencia y permite auditar y rastrear el origen de cada dato. Si una transformación posterior tiene un error o cambian las reglas de limpieza, se puede reprocesar desde la capa raw sin volver a descargar la fuente. También evita perder información que en el momento parecía innecesaria.

3. De los 3 datasets descargados, ¿cuál tiene más valores nulos? ¿Qué implicaciones tiene esto para las etapas siguientes del ciclo de vida?

Ninguno: los tres datasets tienen 0 valores nulos en sus 11 columnas (de un total de 1,665,895 celdas en el dataset 1, 974,424 en el dataset 2 y 1,029,567 en el dataset 3). Esto significa que en las etapas siguientes no se necesita imputar ni eliminar registros por nulos. Sin embargo, la calidad no depende solo de los nulos: alrededor del 50 % de los registros de cada dataset son duplicados exactos y los datasets se solapan entre sí (por ejemplo, los registros únicos del dataset 3 están contenidos en el dataset 1). Por eso, en la transformación habrá que decidir cómo tratar los duplicados y evitar contar dos veces los mismos datos si se combinan.

4. ¿Qué diferencias observas entre los tipos de datos (dtypes) de los 3 datasets? ¿Qué columnas crees que necesitarán conversión de tipo?

No hay diferencias: los tres datasets tienen el mismo esquema. Cuatro columnas son numéricas enteras (work_year, salary, salary_in_usd y remote_ratio, int64) y las otras siete son de texto (object). Las columnas que probablemente necesiten conversión son: experience_level, employment_type y company_size (códigos como EN, MI, SE, EX, FT o S, M, L), que conviene convertir a tipo categórico o decodificar; remote_ratio, que aunque es numérico representa una categoría (0, 50 o 100); work_year, que podría convertirse a fecha si se hacen análisis temporales; y salary_currency, employee_residence y company_location, que son códigos que también conviene manejar como categorías.

5. ¿Qué limitaciones identificas en usar SQLite como almacenamiento para un sistema de datos en producción?

SQLite guarda toda la base en un solo archivo y no funciona como un servidor, por lo que tiene poca capacidad para escrituras concurrentes (solo un proceso escribe a la vez) y no escala bien con muchos usuarios o con grandes volúmenes de datos. No ofrece control de acceso por usuarios ni mecanismos nativos de replicación o alta disponibilidad. Además, al estar almacenada en Google Drive, la base debe descargarse completa para consultarla, lo que agrega latencia y riesgos de sincronización o corrupción si varias personas la usan a la vez. Para producción sería mejor un motor cliente-servidor como PostgreSQL o un almacén de datos en la nube.