Centro Universitario de Guadalajara

Fundamentos de Ingeniería de Datos

ENTREGABLE 2

Canalización ETL/ELT mínima + Reporte de validación

Hito 2: E2.1 Canalización ETL/ELT y E2.2 Reporte de validación

Nombre: Bethzy Sarahi Salcido Toro

Código: 220443324

Nombre: Guillermo Fernando Ornelas Jimenez

Código: 225361237

Fecha de entrega: 7 de noviembre de 2026

Docente: Gustavo Candelario Guzmán

Repositorio: https://github.com/MemoOrnelasJ11/ing_datos

1. Introducción

En esta actividad se construyen las capas EXTRACTED y TRANSFORMED del pipeline iniciado en la Actividad 1, con su carga a Parquet y su validación, para **los tres datasets** de salarios en ciencia de datos descargados de Kaggle. Los tres comparten el mismo esquema de 11 columnas, por lo que el código se escribió una sola vez como funciones que reciben la etiqueta del dataset (`extraer(etiqueta)` y `transformar(etiqueta)`) y sus reglas (`REGLAS[etiqueta]`). Las funciones genéricas de bitácora, limpieza, medición de calidad, validación con DuckDB y log se agregaron a `tools/tools.py`, nuestro archivo de utilidades. Se respetó la regla de oro: cada capa lee solo de la anterior y las tablas RAW se abren en modo solo lectura.

El código completo del proyecto (notebooks, `tools.py`, logs, evidencias y archivos Parquet) está disponible en el repositorio: https://github.com/MemoOrnelasJ11/ing_datos.

Tabla 1. Resumen del pipeline por dataset.

Dataset	Filas RAW	Filas EXTRACTED	Filas Parquet	Eliminadas	Cuadre
adilshamim8	151,445	151,445	71,913	79,532	Sí
samithsachidanandan	88,584	88,584	44,244	44,340	Sí
saurabhbadole	93,597	93,597	46,637	46,960	Sí

2. Mapa del flujo actualizado (lineage general)

El mapa de la Actividad 1 (origen, ingesta y capa RAW) se extiende con las capas EXTRACTED, TRANSFORMED y VALIDACIÓN, junto con los archivos que genera cada una. Las etiquetas son `adilshamim8`, `samithsachidanandan` y `saurabhbadole`.

1. ORIGEN: Kaggle (API externa)

Dataset 1 *adilshamim8/salaries-for-data-science-jobs* · Dataset 2 *samithsachidanandan/the-global-ai-ml-data-science-salary-for-2025* · Dataset 3 *saurabhbadole/latest-data-science-job-salaries-2024*

▼

2. INGESTA (Actividad 1)

Descarga con la API de Kaggle (token) → CSV en `datasets/` y en Drive (KAGGLE_DRIVE_FOLDER).

▼

3. RAW: SQLite, solo lectura

`bases/tabla_1.db`, `tabla_2.db` y `tabla_3.db`, cada una con su tabla `data`. No se modifica; se lee con `?mode=ro`.

▼

4. EXTRACTED: `extracted_<etiqueta>` (notebook extraccion.ipynb)

Agrega `_batch_id`, `_extracted_at`, `_source_table` y `_row_hash`. CDC por huellas con `if_exists='append'`.
Genera: `Extraccion_de_Datos/Logs/cdc_<etiqueta>.json` ×3 y `extraccion_log.jsonl`

▼

5. TRANSFORMED: Parquet (notebook transformacion.ipynb)

Lee solo `extracted_<etiqueta>`. Calidad antes → 14 pasos con bitácora → calidad después → `df_final`.
Genera: `Processed/transformed_<etiqueta>.parquet` ×3 · `Logs/transformacion_log.jsonl` · `Logs/lineage_transformed_<etiqueta>.json` ×3 · `Reportes/bitacora_transformed_<etiqueta>.csv` ×3 · `Reportes/calidad_transformed_<etiqueta>.csv` ×3

▼

6. VALIDACIÓN: DuckDB sobre el Parquet cargado

`DESCRIBE` del esquema, conteo de filas y nulos en columnas obligatorias. El resultado se registra en `transformacion_log.jsonl` (etapa *validacion_duckdb*).

▼

7. REPORTE DE VALIDACIÓN (E2.2)

Este documento se alimenta de las evidencias de las capas EXTRACTED, TRANSFORMED y VALIDACIÓN.

Figura 1. Mapa del flujo de datos actualizado: diagrama de lineage general.

3. Dataset 1: `adilshamim8`

Fuente: `adilshamim8/salaries-for-data-science-jobs` (archivo salaries.csv). Tabla RAW: `data` en `bases/tabla_1.db`; tabla EXTRACTED: `extracted_adilshamim8` en la misma base; salida TRANSFORMED: `transformed_adilshamim8.parquet`.

3.1 Extracción

La tabla RAW se leyó en modo solo lectura (`?mode=ro`). A cada fila se le agregaron los cuatro metadatos de extracción y se calculó su huella SHA-256 (16 caracteres) sobre el contenido de las 11 columnas. En la primera ejecución `extracted_adilshamim8` no existía, así que se hizo una **carga completa**: 151,445 filas en el lote 1. En la segunda ejecución todas las huellas de RAW ya estaban en EXTRACTED, así que la **carga incremental** agregó 0 filas y no abrió un lote nuevo. Las filas de RAW y de EXTRACTED coinciden (151,445 = 151,445). Solo hay 71,913 huellas distintas porque el 52.5% de las filas son duplicados exactos, que generan la misma huella. El control de cambios se compara contra el conjunto de huellas, por lo que esos duplicados no rompen la lógica incremental.

Tabla 2. adilshamim8: filas RAW contra EXTRACTED (SQL).

filas_raw	filas_extracted	huellas_distintas
151,445	151,445	71,913

Tabla 3. adilshamim8: filas por lote en EXTRACTED.

lote	extraido_en	tabla_origen	filas
1	2026-11-07T22:43:08	data	151,445

Tabla 4. adilshamim8: nulos en los metadatos de extracción.

nulos_batch_id	nulos_extracted_at	nulos_source_table	nulos_row_hash
0	0	0	0

Tabla 5. adilshamim8: registros de extraccion_log.jsonl (carga completa y carga incremental).

timestamp	tipo	batch_id	filas_leidas	filas_nuevas	filas_acumuladas	estado
2026-11-07 22:43:08	full_load	1	151,445	151,445	151,445	exitoso
2026-11-07 22:43:10	incremental	1	151,445	0	151,445	exitoso

Estado final del archivo de control `cdc_adilshamim8.json`: último lote 1, 151,445 filas acumuladas, última ejecución de tipo *incremental* (2026-11-07T22:43:10).

3.2 Diagnóstico inicial

Las reglas parten de la miniespecificación de la Actividad 1, que pedía 0 nulos en columnas críticas, `salary_in_usd` > 0, `remote_ratio` solo con 0, 50 o 100, categorías dentro de catálogo y tratar los duplicados exactos en la siguiente capa. Se midieron sobre `extracted_adilshamim8` y se guardaron como línea base (`calidad_antes`).

Tabla 6. adilshamim8: reglas de calidad por dimensión.

Dimensión	Regla	Por qué
Completitud	Nulos por columna. Obligatorias: work_year, experience_level, employment_type, salary, salary_currency y salary_in_usd.	Sin estas columnas no se puede ubicar el salario en el tiempo, ni segmentarlo, ni convertirlo a USD.
Unicidad	Duplicados exactos en las 11 columnas de negocio (sin metadatos).	Las filas repetidas inflan conteos y sesgan promedios y medianas.
Consistencia (entre columnas)	Si salary_currency = USD, entonces salary = salary_in_usd.	Si el pago ya está en dólares, la conversión debe ser la identidad; una diferencia indicaría un error de captura o de conversión.
Consistencia (dominio)	experience_level ∈ {EN, MI, SE, EX}; employment_type ∈ {FT, PT, CT, FL}; company_size ∈ {S, M, L}; remote_ratio ∈ {0, 50, 100}; work_year entre 2020 y 2025; salarios > 0; países con código ISO-2.	Son los catálogos documentados de la fuente; cualquier otro valor sería ruido.

Tabla 7. adilshamim8: calidad antes (sobre extracted_adilshamim8). Los nulos por columna, todos en 0, están en calidad_transformed_adilshamim8.csv.

dimension	metrica	antes
General	filas	151,445
Completitud	nulos_totales	0
Completitud	filas_con_nulo_en_obligatorias	0
Unicidad	duplicados_exactos	79,532
Consistencia	usd_salary_distinto_de_salary_in_usd	0
Consistencia	experience_level_invalido	0
Consistencia	employment_type_invalido	0
Consistencia	company_size_invalido	0
Consistencia	remote_ratio_fuera_de_0_50_100	0
Consistencia	work_year_fuera_de_2020_2025	0
Consistencia	salario_no_positivo	0
Consistencia	pais_no_iso2	0

El dataset no tiene nulos ni violaciones de reglas de consistencia. El único problema de calidad son los **79,532 duplicados exactos** (52.5% de las filas), lo cual coincide con lo observado en la Actividad 1.

3.3 Transformaciones y decisiones

Cada paso quedó registrado en `bitacora_transformed_adilshamim8.csv` con las filas antes, después, eliminadas y afectadas.

Tabla 8. adilshamim8: bitácora de transformaciones.

paso	transformacion	decision	filas_antes	filas_despues	filas_eliminadas	filas_afectadas
1	renombrar_columnas	renombrar	151,445	151,445	0	0
2	limpieza_texto	normalizar	151,445	151,445	0	0
3	nulos_obligatorias	eliminar	151,445	151,445	0	0
4	nulos_job_title	marcar	151,445	151,445	0	0
5	nulos_employee_residence	marcar	151,445	151,445	0	0
6	nulos_company_location	marcar	151,445	151,445	0	0
7	nulos_company_size	marcar	151,445	151,445	0	0
8	nulos_remote_ratio	imputar	151,445	151,445	0	0
9	duplicados_exactos	eliminar	151,445	71,913	79,532	79,532
10	reglas_consistencia	eliminar	71,913	71,913	0	0
11	conversion_tipos	convertir	71,913	71,913	0	71,913
12	columnas_derivadas	derivar	71,913	71,913	0	71,913
13	marcar_atipicos_salario	marcar	71,913	71,913	0	1,754
14	metadatos_transformacion	agregar	71,913	71,913	0	71,913

Justificación de las decisiones.

- **Nombres de columnas y limpieza de texto (0 afectadas).** Las columnas ya venían en snake_case y sin espacios sobrantes. Los pasos se aplican de forma defensiva para que una carga futura con espacios o minúsculas se normalice sola. Los códigos se pasan a mayúsculas para que coincidan con los catálogos.
- **Nulos en obligatorias: eliminar.** Imputar un salario o un año inventaría el dato que se quiere analizar. En esta carga se eliminaron 0 filas.
- **Nulos en opcionales: marcar o imputar.** `job_title` se marca con "Sin especificar" y los países y el tamaño de empresa con "ND", para conservar el salario sin inventar categorías. `remote_ratio` se imputa con la moda (0, presencial). En esta carga hubo 0 nulos.
- **Duplicados exactos: eliminar (79,532 filas).** Se conserva la primera aparición. Al no existir un identificador de respuesta, dos filas idénticas en las 11 columnas no se pueden distinguir y contarlas dos veces sesga cualquier agregado.
- **Reglas de consistencia: eliminar violaciones (0 filas).** Ninguna fila rompió las reglas, pero el paso queda listo para cargas futuras.

- **Conversión de tipos.** Enteros: `work_year` a int16, `remote_ratio` a int8, salarios a int64 y `_batch_id` a int32. Texto a `string`. Fecha: `_extracted_at` a datetime. Booleanos y decimal derivados: `es_remoto_total`, `misma_ubicacion`, `pago_en_usd` y `tasa_cambio_a_usd` (= salary_in_usd / salary).
- **Atípicos de salario: marcar (1,754 filas).** Con la regla IQR, los valores fuera de [-45,472, 331,788] USD se marcan en `_outlier_salario` y no se eliminan, porque pueden ser salarios reales de puestos directivos.
- **Metadatos de transformación.** Se agregan `_transformed_at` y `_transform_version` (v1.0) y se conservan los cuatro metadatos de extracción.

3.4 Validación tras la carga

`df_final` se escribió en `Processed/transformed_adilshamim8.parquet`, sobrescribiendo el archivo, y se leyó de vuelta: los 22 tipos de columna se conservaron y el número de filas coincide. Después se validó el archivo con DuckDB.

Tabla 9. adilshamim8: esquema del Parquet (DuckDB DESCRIBE).

columna	tipo	nulos	columna	tipo	nulos
work_year	SMALLINT	YES	_batch_id	INTEGER	YES
experience_level	VARCHAR	YES	_extracted_at	TIMESTAMP_NS	YES
employment_type	VARCHAR	YES	_source_table	VARCHAR	YES
job_title	VARCHAR	YES	_row_hash	VARCHAR	YES
salary	BIGINT	YES	es_remoto_total	BOOLEAN	YES
salary_currency	VARCHAR	YES	misma_ubicacion	BOOLEAN	YES
salary_in_usd	BIGINT	YES	pago_en_usd	BOOLEAN	YES
employee_residence	VARCHAR	YES	tasa_cambio_a_usd	DOUBLE	YES
remote_ratio	TINYINT	YES	_outlier_salario	BOOLEAN	YES
company_location	VARCHAR	YES	_transformed_at	TIMESTAMP	YES
company_size	VARCHAR	YES	_transform_version	VARCHAR	YES

Tabla 10. adilshamim8: conteo y nulos en columnas obligatorias (DuckDB).

filas	work_year	experience_level	employment_type	salary	salary_currency	salary_in_usd
71,913	0	0	0	0	0	0

Tabla 11. adilshamim8: calidad antes contra después.

dimension	metrica	antes	despues	diferencia
General	filas	151,445	71,913	-79,532
Completitud	nulos_totales	0	0	0
Completitud	filas_con_nulo_en_obligatorias	0	0	0
Unicidad	duplicados_exactos	79,532	0	-79,532
Consistencia	usd_salary_distinto_de_salary_in_usd	0	0	0
Consistencia	experience_level_invalido	0	0	0
Consistencia	employment_type_invalido	0	0	0
Consistencia	company_size_invalido	0	0	0
Consistencia	remote_ratio_fuera_de_0_50_100	0	0	0
Consistencia	work_year_fuera_de_2020_2025	0	0	0
Consistencia	salario_no_positivo	0	0	0
Consistencia	pais_no_iso2	0	0	0

Cuadre de la bitácora. La suma de `filas_eliminadas` en la bitácora es 79,532, y las filas que realmente se perdieron entre EXTRACTED y el Parquet son 151,445 − 71,913 = 79,532. **Cuadra.** Todas las filas eliminadas provienen del paso de duplicados exactos. El lineage (`lineage_transformed_adilshamim8.json`) registra el recorrido, 151,445 filas de origen, 71,913 de destino, la versión de reglas v1.0, la bitácora completa y el tipo de cada columna.

3.5 Hallazgos y limitaciones

- Después de limpiar quedan 71,913 registros únicos (47.5% del original). La mediana de `salary_in_usd` es 138,750 USD y el 24.3% de los puestos son 100 % remotos.
- Es el dataset más completo: tiene 38,282 registros únicos de 2025 y contiene a los otros dos casi por completo, así que funciona como fuente principal.
- Limitación: sin un identificador de respuesta no se puede saber si dos filas idénticas son la misma persona capturada dos veces o dos personas con el mismo puesto, país y salario. Eliminarlas podría subestimar algunos grupos.
- Con más tiempo: pedir o construir un identificador de respuesta, decodificar los códigos de categorías (EN → Entry, etc.), unificar los tres datasets en una sola tabla sin solapes y separar la regla de atípicos por nivel de experiencia y país.

4. Dataset 2: `samithsachidanandan`

Fuente: `samithsachidanandan/the-global-ai-ml-data-science-salary-for-2025` (archivo salaries2.csv (salaries.csv en Kaggle)). Tabla RAW: `data` en `bases/tabla_2.db`; tabla EXTRACTED: `extracted_samithsachidanandan` en la misma base; salida TRANSFORMED: `transformed_samithsachidanandan.parquet`.

4.1 Extracción

La tabla RAW se leyó en modo solo lectura (`?mode=ro`). A cada fila se le agregaron los cuatro metadatos de extracción y se calculó su huella SHA-256 (16 caracteres) sobre el contenido de las 11 columnas. En la primera ejecución `extracted_samithsachidanandan` no existía, así que se hizo una **carga completa**: 88,584 filas en el lote 1. En la segunda ejecución todas las huellas de RAW ya estaban en EXTRACTED, así que la **carga incremental** agregó 0 filas y no abrió un lote nuevo. Las filas de RAW y de EXTRACTED coinciden (88,584 = 88,584). Solo hay 44,244 huellas distintas porque el 50.1% de las filas son duplicados exactos, que generan la misma huella. El control de cambios se compara contra el conjunto de huellas, por lo que esos duplicados no rompen la lógica incremental.

Tabla 12. samithsachidanandan: filas RAW contra EXTRACTED (SQL).

filas_raw	filas_extracted	huellas_distintas
88,584	88,584	44,244

Tabla 13. samithsachidanandan: filas por lote en EXTRACTED.

lote	extraido_en	tabla_origen	filas
1	2026-11-07T22:43:09	data	88,584

Tabla 14. samithsachidanandan: nulos en los metadatos de extracción.

nulos_batch_id	nulos_extracted_at	nulos_source_table	nulos_row_hash
0	0	0	0

Tabla 15. samithsachidanandan: registros de extraccion_log.jsonl (carga completa y carga incremental).

timestamp	tipo	batch_id	filas_leidas	filas_nuevas	filas_acumuladas	estado
2026-11-07 22:43:09	full_load	1	88,584	88,584	88,584	exitoso
2026-11-07 22:43:10	incremental	1	88,584	0	88,584	exitoso

Estado final del archivo de control `cdc_samithsachidanandan.json`: último lote 1, 88,584 filas acumuladas, última ejecución de tipo *incremental* (2026-11-07T22:43:10).

4.2 Diagnóstico inicial

Las reglas parten de la miniespecificación de la Actividad 1, que pedía 0 nulos en columnas críticas, `salary_in_usd` > 0, `remote_ratio` solo con 0, 50 o 100, categorías dentro de catálogo y tratar los duplicados exactos en la siguiente capa. Se midieron sobre `extracted_samithsachidanandan` y se guardaron como línea base (`calidad_antes`).

Tabla 16. samithsachidanandan: reglas de calidad por dimensión.

Dimensión	Regla	Por qué
Completitud	Nulos por columna. Obligatorias: work_year, experience_level, employment_type, salary, salary_currency y salary_in_usd.	Sin estas columnas no se puede ubicar el salario en el tiempo, ni segmentarlo, ni convertirlo a USD.
Unicidad	Duplicados exactos en las 11 columnas de negocio (sin metadatos).	Las filas repetidas inflan conteos y sesgan promedios y medianas.
Consistencia (entre columnas)	Si salary_currency = USD, entonces salary = salary_in_usd.	Si el pago ya está en dólares, la conversión debe ser la identidad; una diferencia indicaría un error de captura o de conversión.
Consistencia (dominio)	experience_level ∈ {EN, MI, SE, EX}; employment_type ∈ {FT, PT, CT, FL}; company_size ∈ {S, M, L}; remote_ratio ∈ {0, 50, 100}; work_year entre 2020 y 2025; salarios > 0; países con código ISO-2.	Son los catálogos documentados de la fuente; cualquier otro valor sería ruido.

Tabla 17. samithsachidanandan: calidad antes (sobre extracted_samithsachidanandan). Los nulos por columna, todos en 0, están en calidad_transformed_samithsachidanandan.csv.

dimension	metrica	antes
General	filas	88,584
Completitud	nulos_totales	0
Completitud	filas_con_nulo_en_obligatorias	0
Unicidad	duplicados_exactos	44,340
Consistencia	usd_salary_distinto_de_salary_in_usd	0
Consistencia	experience_level_invalido	0
Consistencia	employment_type_invalido	0
Consistencia	company_size_invalido	0
Consistencia	remote_ratio_fuera_de_0_50_100	0
Consistencia	work_year_fuera_de_2020_2025	0
Consistencia	salario_no_positivo	0
Consistencia	pais_no_iso2	0

El dataset no tiene nulos ni violaciones de reglas de consistencia. El único problema de calidad son los **44,340 duplicados exactos** (50.1% de las filas), lo cual coincide con lo observado en la Actividad 1.

4.3 Transformaciones y decisiones

Cada paso quedó registrado en `bitacora_transformed_samithsachidanandan.csv` con las filas antes, después, eliminadas y afectadas.

Tabla 18. samithsachidanandan: bitácora de transformaciones.

paso	transformacion	decision	filas_antes	filas_despues	filas_eliminadas	filas_afectadas
1	renombrar_columnas	renombrar	88,584	88,584	0	0
2	limpieza_texto	normalizar	88,584	88,584	0	0
3	nulos_obligatorias	eliminar	88,584	88,584	0	0
4	nulos_job_title	marcar	88,584	88,584	0	0
5	nulos_employee_residence	marcar	88,584	88,584	0	0
6	nulos_company_location	marcar	88,584	88,584	0	0
7	nulos_company_size	marcar	88,584	88,584	0	0
8	nulos_remote_ratio	imputar	88,584	88,584	0	0
9	duplicados_exactos	eliminar	88,584	44,244	44,340	44,340
10	reglas_consistencia	eliminar	44,244	44,244	0	0
11	conversion_tipos	convertir	44,244	44,244	0	44,244
12	columnas_derivadas	derivar	44,244	44,244	0	44,244
13	marcar_atipicos_salario	marcar	44,244	44,244	0	1,051
14	metadatos_transformacion	agregar	44,244	44,244	0	44,244

Justificación de las decisiones.

- **Nombres de columnas y limpieza de texto (0 afectadas).** Las columnas ya venían en snake_case y sin espacios sobrantes. Los pasos se aplican de forma defensiva para que una carga futura con espacios o minúsculas se normalice sola. Los códigos se pasan a mayúsculas para que coincidan con los catálogos.
- **Nulos en obligatorias: eliminar.** Imputar un salario o un año inventaría el dato que se quiere analizar. En esta carga se eliminaron 0 filas.
- **Nulos en opcionales: marcar o imputar.** `job_title` se marca con "Sin especificar" y los países y el tamaño de empresa con "ND", para conservar el salario sin inventar categorías. `remote_ratio` se imputa con la moda (0, presencial). En esta carga hubo 0 nulos.
- **Duplicados exactos: eliminar (44,340 filas).** Se conserva la primera aparición. Al no existir un identificador de respuesta, dos filas idénticas en las 11 columnas no se pueden distinguir y contarlas dos veces sesga cualquier agregado.
- **Reglas de consistencia: eliminar violaciones (0 filas).** Ninguna fila rompió las reglas, pero el paso queda listo para cargas futuras.

- **Conversión de tipos.** Enteros: `work_year` a int16, `remote_ratio` a int8, salarios a int64 y `_batch_id` a int32. Texto a `string`. Fecha: `_extracted_at` a datetime. Booleanos y decimal derivados: `es_remoto_total`, `misma_ubicacion`, `pago_en_usd` y `tasa_cambio_a_usd` (= salary_in_usd / salary).
- **Atípicos de salario: marcar (1,051 filas).** Con la regla IQR, los valores fuera de [-44,972, 331,488] USD se marcan en `_outlier_salario` y no se eliminan, porque pueden ser salarios reales de puestos directivos.
- **Metadatos de transformación.** Se agregan `_transformed_at` y `_transform_version` (v1.0) y se conservan los cuatro metadatos de extracción.

4.4 Validación tras la carga

`df_final` se escribió en `Processed/transformed_samithsachidanandan.parquet`, sobrescribiendo el archivo, y se leyó de vuelta: los 22 tipos de columna se conservaron y el número de filas coincide. Después se validó el archivo con DuckDB.

Tabla 19. samithsachidanandan: esquema del Parquet (DuckDB DESCRIBE).

columna	tipo	nulos	columna	tipo	nulos
work_year	SMALLINT	YES	_batch_id	INTEGER	YES
experience_level	VARCHAR	YES	_extracted_at	TIMESTAMP_NS	YES
employment_type	VARCHAR	YES	_source_table	VARCHAR	YES
job_title	VARCHAR	YES	_row_hash	VARCHAR	YES
salary	BIGINT	YES	es_remoto_total	BOOLEAN	YES
salary_currency	VARCHAR	YES	misma_ubicacion	BOOLEAN	YES
salary_in_usd	BIGINT	YES	pago_en_usd	BOOLEAN	YES
employee_residence	VARCHAR	YES	tasa_cambio_a_usd	DOUBLE	YES
remote_ratio	TINYINT	YES	_outlier_salario	BOOLEAN	YES
company_location	VARCHAR	YES	_transformed_at	TIMESTAMP	YES
company_size	VARCHAR	YES	_transform_version	VARCHAR	YES

Tabla 20. samithsachidanandan: conteo y nulos en columnas obligatorias (DuckDB).

filas	work_year	experience_level	employment_type	salary	salary_currency	salary_in_usd
44,244	0	0	0	0	0	0

Tabla 21. samithsachidanandan: calidad antes contra después.

dimension	metrica	antes	despues	diferencia
General	filas	88,584	44,244	-44,340
Completitud	nulos_totales	0	0	0
Completitud	filas_con_nulo_en_obligatorias	0	0	0
Unicidad	duplicados_exactos	44,340	0	-44,340
Consistencia	usd_salary_distinto_de_salary_in_usd	0	0	0
Consistencia	experience_level_invalido	0	0	0
Consistencia	employment_type_invalido	0	0	0
Consistencia	company_size_invalido	0	0	0
Consistencia	remote_ratio_fuera_de_0_50_100	0	0	0
Consistencia	work_year_fuera_de_2020_2025	0	0	0
Consistencia	salario_no_positivo	0	0	0
Consistencia	pais_no_iso2	0	0	0

Cuadre de la bitácora. La suma de `filas_eliminadas` en la bitácora es 44,340, y las filas que realmente se perdieron entre EXTRACTED y el Parquet son 88,584 − 44,244 = 44,340. **Cuadra.** Todas las filas eliminadas provienen del paso de duplicados exactos. El lineage (`lineage_transformed_samithsachidanandan.json`) registra el recorrido, 88,584 filas de origen, 44,244 de destino, la versión de reglas v1.0, la bitácora completa y el tipo de cada columna.

4.5 Hallazgos y limitaciones

- Después de limpiar quedan 44,244 registros únicos (49.9% del original). La mediana de `salary_in_usd` es 139,200 USD y el 24.6% de los puestos son 100 % remotos.
- Ya sin duplicados, 44,243 de sus 44,244 registros también aparecen en `adilshamim8`. Solo aporta un registro propio, lo que confirma la redundancia señalada en la Actividad 1.
- Limitación: sin un identificador de respuesta no se puede saber si dos filas idénticas son la misma persona capturada dos veces o dos personas con el mismo puesto, país y salario. Eliminarlas podría subestimar algunos grupos.
- Con más tiempo: pedir o construir un identificador de respuesta, decodificar los códigos de categorías (EN → Entry, etc.), unificar los tres datasets en una sola tabla sin solapes y separar la regla de atípicos por nivel de experiencia y país.

5. Dataset 3: `saurabhbadole`

Fuente: `saurabhbadole/latest-data-science-job-salaries-2024` (archivo DataScience_salaries_2025.csv). Tabla RAW: `data` en `bases/tabla_3.db`; tabla EXTRACTED: `extracted_saurabhbadole` en la misma base; salida TRANSFORMED: `transformed_saurabhbadole.parquet`.

5.1 Extracción

La tabla RAW se leyó en modo solo lectura (`?mode=ro`). A cada fila se le agregaron los cuatro metadatos de extracción y se calculó su huella SHA-256 (16 caracteres) sobre el contenido de las 11 columnas. En la primera ejecución `extracted_saurabhbadole` no existía, así que se hizo una **carga completa**: 93,597 filas en el lote 1. En la segunda ejecución todas las huellas de RAW ya estaban en EXTRACTED, así que la **carga incremental** agregó 0 filas y no abrió un lote nuevo. Las filas de RAW y de EXTRACTED coinciden (93,597 = 93,597). Solo hay 46,637 huellas distintas porque el 50.2% de las filas son duplicados exactos, que generan la misma huella. El control de cambios se compara contra el conjunto de huellas, por lo que esos duplicados no rompen la lógica incremental.

Tabla 22. saurabhbadole: filas RAW contra EXTRACTED (SQL).

filas_raw	filas_extracted	huellas_distintas
93,597	93,597	46,637

Tabla 23. saurabhbadole: filas por lote en EXTRACTED.

lote	extraido_en	tabla_origen	filas
1	2026-11-07T22:43:09	data	93,597

Tabla 24. saurabhbadole: nulos en los metadatos de extracción.

nulos_batch_id	nulos_extracted_at	nulos_source_table	nulos_row_hash
0	0	0	0

Tabla 25. saurabhbadole: registros de extraccion_log.jsonl (carga completa y carga incremental).

timestamp	tipo	batch_id	filas_leidas	filas_nuevas	filas_acumuladas	estado
2026-11-07 22:43:09	full_load	1	93,597	93,597	93,597	exitoso
2026-11-07 22:43:11	incremental	1	93,597	0	93,597	exitoso

Estado final del archivo de control `cdc_saurabhbadole.json`: último lote 1, 93,597 filas acumuladas, última ejecución de tipo *incremental* (2026-11-07T22:43:11).

5.2 Diagnóstico inicial

Las reglas parten de la miniespecificación de la Actividad 1, que pedía 0 nulos en columnas críticas, `salary_in_usd` > 0, `remote_ratio` solo con 0, 50 o 100, categorías dentro de catálogo y tratar los duplicados exactos en la siguiente capa. Se midieron sobre `extracted_saurabhbadole` y se guardaron como línea base (`calidad_antes`).

Tabla 26. saurabhbadole: reglas de calidad por dimensión.

Dimensión	Regla	Por qué
Completitud	Nulos por columna. Obligatorias: work_year, experience_level, employment_type, salary, salary_currency y salary_in_usd.	Sin estas columnas no se puede ubicar el salario en el tiempo, ni segmentarlo, ni convertirlo a USD.
Unicidad	Duplicados exactos en las 11 columnas de negocio (sin metadatos).	Las filas repetidas inflan conteos y sesgan promedios y medianas.
Consistencia (entre columnas)	Si salary_currency = USD, entonces salary = salary_in_usd.	Si el pago ya está en dólares, la conversión debe ser la identidad; una diferencia indicaría un error de captura o de conversión.
Consistencia (dominio)	experience_level ∈ {EN, MI, SE, EX}; employment_type ∈ {FT, PT, CT, FL}; company_size ∈ {S, M, L}; remote_ratio ∈ {0, 50, 100}; work_year entre 2020 y 2025; salarios > 0; países con código ISO-2.	Son los catálogos documentados de la fuente; cualquier otro valor sería ruido.

Tabla 27. saurabhbadole: calidad antes (sobre extracted_saurabhbadole). Los nulos por columna, todos en 0, están en calidad_transformed_saurabhbadole.csv.

dimension	metrica	antes
General	filas	93,597
Completitud	nulos_totales	0
Completitud	filas_con_nulo_en_obligatorias	0
Unicidad	duplicados_exactos	46,960
Consistencia	usd_salary_distinto_de_salary_in_usd	0
Consistencia	experience_level_invalido	0
Consistencia	employment_type_invalido	0
Consistencia	company_size_invalido	0
Consistencia	remote_ratio_fuera_de_0_50_100	0
Consistencia	work_year_fuera_de_2020_2025	0
Consistencia	salario_no_positivo	0
Consistencia	pais_no_iso2	0

El dataset no tiene nulos ni violaciones de reglas de consistencia. El único problema de calidad son los **46,960 duplicados exactos** (50.2% de las filas), lo cual coincide con lo observado en la Actividad 1.

5.3 Transformaciones y decisiones

Cada paso quedó registrado en `bitacora_transformed_saurabhbadole.csv` con las filas antes, después, eliminadas y afectadas.

Tabla 28. saurabhbadole: bitácora de transformaciones.

paso	transformacion	decision	filas_antes	filas_despues	filas_eliminadas	filas_afectadas
1	renombrar_columnas	renombrar	93,597	93,597	0	0
2	limpieza_texto	normalizar	93,597	93,597	0	0
3	nulos_obligatorias	eliminar	93,597	93,597	0	0
4	nulos_job_title	marcar	93,597	93,597	0	0
5	nulos_employee_residence	marcar	93,597	93,597	0	0
6	nulos_company_location	marcar	93,597	93,597	0	0
7	nulos_company_size	marcar	93,597	93,597	0	0
8	nulos_remote_ratio	imputar	93,597	93,597	0	0
9	duplicados_exactos	eliminar	93,597	46,637	46,960	46,960
10	reglas_consistencia	eliminar	46,637	46,637	0	0
11	conversion_tipos	convertir	46,637	46,637	0	46,637
12	columnas_derivadas	derivar	46,637	46,637	0	46,637
13	marcar_atipicos_salario	marcar	46,637	46,637	0	1,114
14	metadatos_transformacion	agregar	46,637	46,637	0	46,637

Justificación de las decisiones.

- **Nombres de columnas y limpieza de texto (0 afectadas).** Las columnas ya venían en snake_case y sin espacios sobrantes. Los pasos se aplican de forma defensiva para que una carga futura con espacios o minúsculas se normalice sola. Los códigos se pasan a mayúsculas para que coincidan con los catálogos.
- **Nulos en obligatorias: eliminar.** Imputar un salario o un año inventaría el dato que se quiere analizar. En esta carga se eliminaron 0 filas.
- **Nulos en opcionales: marcar o imputar.** `job_title` se marca con "Sin especificar" y los países y el tamaño de empresa con "ND", para conservar el salario sin inventar categorías. `remote_ratio` se imputa con la moda (0, presencial). En esta carga hubo 0 nulos.
- **Duplicados exactos: eliminar (46,960 filas).** Se conserva la primera aparición. Al no existir un identificador de respuesta, dos filas idénticas en las 11 columnas no se pueden distinguir y contarlas dos veces sesga cualquier agregado.
- **Reglas de consistencia: eliminar violaciones (0 filas).** Ninguna fila rompió las reglas, pero el paso queda listo para cargas futuras.

- **Conversión de tipos.** Enteros: `work_year` a int16, `remote_ratio` a int8, salarios a int64 y `_batch_id` a int32. Texto a `string`. Fecha: `_extracted_at` a datetime. Booleanos y decimal derivados: `es_remoto_total`, `misma_ubicacion`, `pago_en_usd` y `tasa_cambio_a_usd` (= salary_in_usd / salary).
- **Atípicos de salario: marcar (1,114 filas).** Con la regla IQR, los valores fuera de [-44,750, 331,650] USD se marcan en `_outlier_salario` y no se eliminan, porque pueden ser salarios reales de puestos directivos.
- **Metadatos de transformación.** Se agregan `_transformed_at` y `_transform_version` (v1.0) y se conservan los cuatro metadatos de extracción.

5.4 Validación tras la carga

`df_final` se escribió en `Processed/transformed_saurabhbadole.parquet`, sobrescribiendo el archivo, y se leyó de vuelta: los 22 tipos de columna se conservaron y el número de filas coincide. Después se validó el archivo con DuckDB.

Tabla 29. saurabhbadole: esquema del Parquet (DuckDB DESCRIBE).

columna	tipo	nulos	columna	tipo	nulos
work_year	SMALLINT	YES	_batch_id	INTEGER	YES
experience_level	VARCHAR	YES	_extracted_at	TIMESTAMP_NS	YES
employment_type	VARCHAR	YES	_source_table	VARCHAR	YES
job_title	VARCHAR	YES	_row_hash	VARCHAR	YES
salary	BIGINT	YES	es_remoto_total	BOOLEAN	YES
salary_currency	VARCHAR	YES	misma_ubicacion	BOOLEAN	YES
salary_in_usd	BIGINT	YES	pago_en_usd	BOOLEAN	YES
employee_residence	VARCHAR	YES	tasa_cambio_a_usd	DOUBLE	YES
remote_ratio	TINYINT	YES	_outlier_salario	BOOLEAN	YES
company_location	VARCHAR	YES	_transformed_at	TIMESTAMP	YES
company_size	VARCHAR	YES	_transform_version	VARCHAR	YES

Tabla 30. saurabhbadole: conteo y nulos en columnas obligatorias (DuckDB).

filas	work_year	experience_level	employment_type	salary	salary_currency	salary_in_usd
46,637	0	0	0	0	0	0

Tabla 31. saurabhbadole: calidad antes contra después.

dimension	metrica	antes	despues	diferencia
General	filas	93,597	46,637	-46,960
Completitud	nulos_totales	0	0	0
Completitud	filas_con_nulo_en_obligatorias	0	0	0
Unicidad	duplicados_exactos	46,960	0	-46,960
Consistencia	usd_salary_distinto_de_salary_in_usd	0	0	0
Consistencia	experience_level_invalido	0	0	0
Consistencia	employment_type_invalido	0	0	0
Consistencia	company_size_invalido	0	0	0
Consistencia	remote_ratio_fuera_de_0_50_100	0	0	0
Consistencia	work_year_fuera_de_2020_2025	0	0	0
Consistencia	salario_no_positivo	0	0	0
Consistencia	pais_no_iso2	0	0	0

Cuadre de la bitácora. La suma de `filas_eliminadas` en la bitácora es 46,960, y las filas que realmente se perdieron entre EXTRACTED y el Parquet son 93,597 − 46,637 = 46,960. **Cuadra.** Todas las filas eliminadas provienen del paso de duplicados exactos. El lineage (`lineage_transformed_saurabhbadole.json`) registra el recorrido, 93,597 filas de origen, 46,637 de destino, la versión de reglas v1.0, la bitácora completa y el tipo de cada columna.

5.5 Hallazgos y limitaciones

- Después de limpiar quedan 46,637 registros únicos (49.8% del original). La mediana de `salary_in_usd` es 139,100 USD y el 24.6% de los puestos son 100 % remotos.
- Ya sin duplicados, sus 46,637 registros están contenidos en `adilshamim8`. Es un subconjunto del dataset 1 con un corte de 2025 más corto.
- Limitación: sin un identificador de respuesta no se puede saber si dos filas idénticas son la misma persona capturada dos veces o dos personas con el mismo puesto, país y salario. Eliminarlas podría subestimar algunos grupos.
- Con más tiempo: pedir o construir un identificador de respuesta, decodificar los códigos de categorías (EN → Entry, etc.), unificar los tres datasets en una sola tabla sin solapes y separar la regla de atípicos por nivel de experiencia y país.

6. Conclusiones

Se implementó la canalización completa para los tres datasets. La capa EXTRACTED agrega metadatos y control de cambios por huellas, y quedó comprobado que una segunda ejecución no duplica datos. La capa TRANSFORMED aplica 14 pasos documentados, y en los tres casos la bitácora cuadra con las filas que realmente se perdieron. Los Parquet conservan los tipos y pasan la validación con DuckDB, sin nulos en columnas obligatorias. El hallazgo principal es que la calidad de estos datos no depende de los nulos, que no existen, sino de la duplicación: alrededor del 50 % de cada dataset son duplicados exactos y, una vez limpios, los datasets 2 y 3 están prácticamente contenidos en el dataset 1. Para la capa de consumo conviene usar `transformed_adilshamim8` como fuente principal y no sumar los tres datasets, para no contar los mismos registros dos o tres veces.