Act. 2 Canalización ETL/ELT mínima + Reporte de validación

1. Datos generales

Campo	Detalle
Unidad	Unidad 2. ETL/ELT y transformaciones
Evidencia	Hito 2: Canalización ETL/ELT + Reporte de validación
Ponderación	25% de la calificación final
Modalidad de trabajo	En parejas

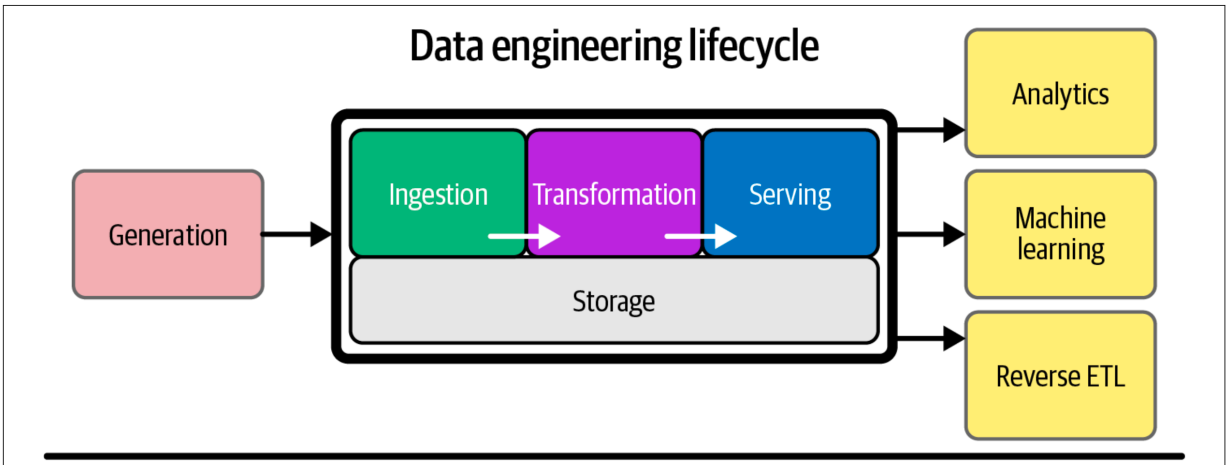
2. Propósito de esta evidencia

Esta actividad corresponde al resultado de aprendizaje de la Unidad 2: “Aplicar modelos ETL/ELT y transformaciones en canalizaciones reproducibles con documentación de cambios”.

Cubre las dos evidencias de la unidad: **E2.1** Canalización ETL/ELT mínima con transformación documentada y lineage, y **E2.2** Reporte de validación (pruebas de esquema y métricas de calidad tras la carga).

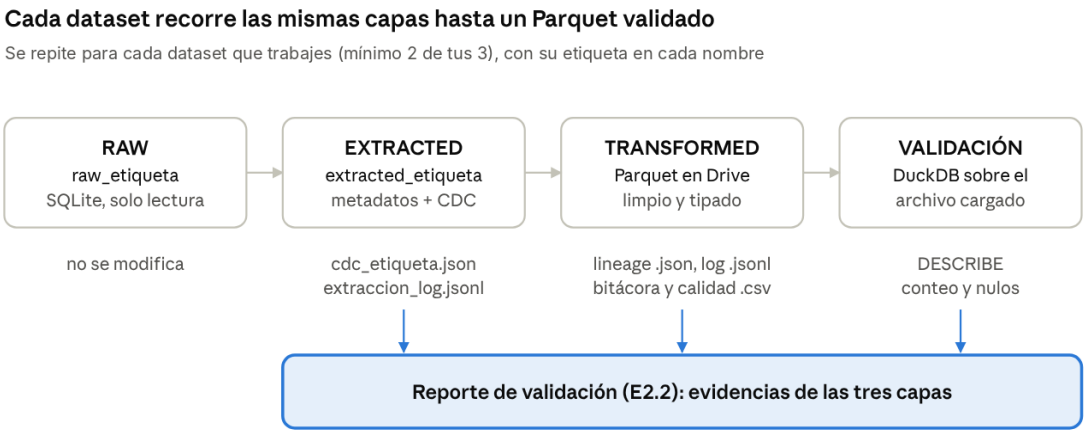
3. Caso de trabajo

Continúas con los **mismos 3 datasets de Kaggle** que ingestaste en la Actividad 1 y que ya están en tu `base_datos.db` como tablas `raw_<etiqueta>`. Ahora construyes las capas siguientes del pipeline para **al menos 2 de los 3 datasets** (puedes trabajar los 3): la capa EXTRACTED, la capa TRANSFORMED y su carga en Parquet, con su validación.



Toma como referencia los notebooks vistos en clase: **EXTRACCION** (capa EXTRACTED) y **TRANSFORMACION** (capa TRANSFORMED, de este ultimo hay dos versiones, la única diferencia es que la versión "TRANSFORMACIONv2.ipynb" aplica solo 3 transformaciones). Esos notebooks trabajan con un solo dataset (`raw_df1`, videojuegos en mi caso); tú debes adaptarlos a por lo menos 2 de tus 3 datasets y, sobre todo, **definir las reglas de limpieza que tus datos necesitan (TRASNFORMACIONES)**. No se trata de copiar las reglas del notebook.

Respeta la regla de oro: cada capa lee solo de la anterior. Las tablas `raw_<etiqueta>` se leen en modo solo lectura y nunca se modifican.



Los archivos bajo cada capa son las evidencias que alimentan el reporte de validación.

4. Capa EXTRACTED

Resultado: al menos 2 tablas `extracted_<etiqueta>` en `base_datos.db` (una por cada dataset que elegiste), cada una con metadatos, control de cambios y log. Para **CADA DATSET** elegido:

1. **Leer el origen** `raw_<etiqueta>` en modo solo lectura (`?mode=ro`).
2. **Agregar los 4 metadatos de extracción** a cada fila: `_batch_id`, `_extracted_at`, `_source_table` y `_row_hash` (huella del contenido de la fila).
3. **Control de cambios con huellas:** comparar las huellas de RAW con las que ya están en EXTRACTED y agregar solo las filas nuevas con `if_exists='append'`. Usa un archivo de control por tabla: `cdc_<etiqueta>.json`.
4. **Log:** registrar cada ejecución con una línea JSON por operación. Puede ser un solo log para todas las tablas, porque cada línea indica su tabla de origen.
5. **Verificar con SQL:** filas de RAW contra EXTRACTED, filas por lote y metadatos sin nulos.

5. Capa TRANSFORMED

Resultado: para **CADA DATSET** elegido (mínimo 2), un `df_final` limpio, una bitácora de transformaciones y la tabla de calidad antes vs. después. La capa TRANSFORMED lee `extracted_<etiqueta>`, nunca `raw_<etiqueta>`.

5.1 Diagnóstico de calidad (antes)

Mide las dimensiones sobre `extracted_<etiqueta>` y guarda la línea base (`calidad_antes`). Las reglas las defines tú para cada dataset; las reglas de calidad de tu miniespecificación (Actividad 1) son el punto de partida.

Dimensión	Qué debes definir y medir	Ejemplo
Completitud	Nulos por columna y cuáles columnas son obligatorias	Year: 271 nulos; Publisher: 58
Unicidad	Duplicados exactos	0 duplicados
Consistencia	Al menos una regla entre columnas	Global_Sales ≈ suma de las regiones

Si tu dataset no tiene columnas que deban cuadrar entre sí, propón otra regla de consistencia (si es necesario) o justifica por qué no aplica.

5.2 Transformaciones mínimas por dataset

Cada transformación se registra en la bitácora con sus filas antes, después y afectadas. Agrega las que tu dataset necesite; estas son el mínimo:

1. Nombres de columnas `remplazando espacio por “_”`
2. Limpieza de las columnas de texto (espacios al inicio, al final y dobles, si es que aplica).
3. Tratamiento de nulos, con la decisión justificada por columna: eliminar, imputar o marcar.
4. Eliminación de duplicados exactos.
5. Conversión de tipos de dato: enteros, decimales, fechas y booleanos.
6. Metadatos de transformación (`_transformed_at`, `_transform_version`), conservando los de extracción.

5.3 Diagnóstico de calidad (después)

Repite las mismas mediciones sobre `df_final`, arma la tabla antes vs. después y comprueba que las filas eliminadas según la **bitácora** coincidan con las que realmente se perdieron.

6. Carga a Parquet, lineage y validación

Resultado: por cada dataset, un archivo Parquet validado y sus evidencias en Google Drive (si es el caso). Para cada dataset:

1. **Carga:** escribe `df_final` en `transformed_<etiqueta>.parquet` dentro de `Transformacion_de_Datos/Processed/`, sobrescribiendo el archivo. Registra la carga en el log y léelo de vuelta para comprobar que conserva los tipos.
2. **Lineage:** guarda `lineage_transformed_<etiqueta>.json` en `Logs/`, con el recorrido del dato, filas de origen y destino, versión de las reglas, la bitácora y el tipo de cada columna.

3. **Evidencias:** guarda `bitacora_transformed_<etiqueta>.csv` y `calidad_transformed_<etiqueta>.csv` en `Reportes/`.
4. **Validación con DuckDB sobre el archivo cargado:** `DESCRIBE` para el esquema y una consulta de conteo y nulos en tus columnas obligatorias.

Al terminar, tu Drive debe tener esta estructura (× N = un archivo por cada dataset trabajado, mínimo 2):

```
Extraccion_de_Datos/Logs/
    cdc_<etiqueta>.json                  × N
    extraccion_log.jsonl

Transformacion_de_Datos/
    Processed/  transformed_<etiqueta>.parquet          × N
    Logs/       transformacion_log.jsonl
                lineage_transformed_<etiqueta>.json     × N
    Reportes/   bitacora_transformed_<etiqueta>.csv     × N
                calidad_transformed_<etiqueta>.csv      × N
```

7. Entregables

E2.1 — Canalización ETL/ELT

- Notebooks `.ipynb` de extracción y de transformación de al menos 1 de tus 3 datasets, **ejecutados y con sus salidas visibles**.
- Tu `utils.py`, agregar funciones nuevas a su archivo **utils.py**.
- Los archivos que generó el pipeline (sección 6): logs, control de cambios, lineage, evidencias y los Parquet (uno por dataset trabajado, mínimo 2).
- En un archivo ZIP empaqueten sus carpetas y súbanla a la plataforma

E2.2 — Reporte de validación

El reporte inicia con un **mapa del flujo actualizado**: el de la Actividad 1, extendido con las capas EXTRACTED y TRANSFORMED y los archivos que genera cada una. Ese mapa es el diagrama de lineage general.

Después, una sección por cada dataset trabajado (mínimo 2), encabezada con su etiqueta, que contenga:

1. **Extracción:** filas de RAW contra EXTRACTED, lotes y evidencia de la carga completa y de la incremental.
2. **Diagnóstico inicial:** las reglas que definiste para cada dimensión, por qué, y la tabla de calidad "antes".
3. **Transformaciones y decisiones:** la bitácora y la justificación de cada decisión (por qué eliminar, imputar o marcar).
4. **Validación tras la carga:** el esquema del Parquet (`DESCRIBE`), el conteo y los nulos, la tabla antes vs. después y el cuadre de la bitácora.
5. **Hallazgos y limitaciones:** lo que encontraste en los datos y lo que harías con más tiempo.

8. Formato de entrega

- **Reporte de validación** en PDF Nomenclatura sugerida: `Apellidos_Actividad_2.pdf`.
- **Carpeta comprimida** con el notebook y los archivos generados. Nomenclatura sugerida: `Apellidos_Actividad_2.zip`.
- Entrega: En Classroom se menciona

Formato de redacción del reporte: tipografía Times New Roman, tamaño 12, interlineado 1.5, texto justificado.

